nipa 정보통신산업진흥원 National IT Industry Promotion Agency

# AI반도체지원본부 추진사업 업무보고

(2026.01, NIPA AI반도체지원본부)

## □ 업무 개요

○ 차세대 성장동력이자 **전산업의 지능화**에 필요한 국산 AI반도체 경쟁력 강화 및 생태계 조성을 위해 **AI반도체 활용 및 확산 지원**

※ 국정과제77(p132) 디지털 경제 패권국가 실현(초일류AI, 도전적 R&D, AI반도체 육성), (과기정통부, '22.06.28) AI반도체 산업성장 지원대책 (정부1.2조 투자, 초기수요시장, 글로벌 시장선도 등)

- AI반도체 실증지원·혁신기업 육성 등 **AI반도체 산업육성 지원**
- AI반도체 초기수요 시장 확대·생태계 조성을 위한 **수요발굴**
- AI반도체 **기술인재 공급** 및 글로벌 AI반도체 **적용·확산 지원**
- AI반도체 **산업육성 전략 사업화** 및 **정부 정책 지원**

## □ 주요 사업

| 사업명 | | | '25년 예산 (백만원) | '26년 예산 (백만원) |
|---|---|---|---|---|
| **(세부) AI반도체 실증지원** | | | | |
| | **(내역) AI반도체 응용실증지원** | | **9,370** | **4,685** |
| | **(내역) AI반도체 Farm 구축 및 실증** | | **6,000** | *('25년 일몰)* |
| | **(내역) 국산 AI반도체 조기상용화 지원** | | **40,000** | **68,685** |
| | | AI컴퓨팅 실증 인프라 고도화 | **12,000** | **16,000** |
| | | 국산 AI반도체 기반 AX디바이스 개발·실증 | | |
| | | 1. 국산AI반도체 기반 AX 디바이스 개발·실증 (미니트랙) | - | **4,685** |
| | | AI반도체 사업화 적시지원 | **22,000** | **30,000** |
| | | 1. 고비용 AI반도체 설계SW 지원 | **2,000** | **2,000** |
| | | 2 시제품 및 양산품 제작 지원 | **17,000** | **21,500** |
| | | 3. AI반도체 검증체계 구축 | **2,500** | **6,000** |
| | | 4 설계 검증장비 활용지원 | **500** | **500** |
| | **(내역) AX실증지원** | | **4,000** | **16,000** |
| | **(내역) AI반도체 최적화 설계지원** | | **30,000** | - |
| | | AI모델 맞춤형 설계지원 | **10,000** | *('25년 일몰)* |
| | | AI반도체 설계 IP 활용지원 | **20,000** | *('25년 일몰)* |
| **(세부) AI반도체 지원플랫폼** | | | | |
| | **(내역)** AI반도체 기술인재 공급 플랫폼 | | **3,500** | **2,250** |
| **(세부) 글로벌ICT혁신클러스터조성** | | | | |
| | **(내역)** AI반도체 클러스터 | | **1,099** | *('25년 일몰)* |

< AI반도체 全주기 지원체계 기반 사업 추진 >

○ **[설 계]** AI반도체 설계SW 맞춤형 지원

· **(수행)** 국산 NPU의 AI모델 호환성 확대·맞춤형 설계 지원과 설계에 필요한 IP 활용 지원 및 설계SW 맞춤형 지원

▸ **('26년)** 설계SW 수요기업 지원 지속, '25년 일몰 사업 후속을 위한 '27년 중기예산 반영 중

○ **[제작 · 검증]** AI반도체 제작 지원을 위한 사업화 적시 지원

· **(수행)** AI반도체 시제품·양산품 제작비용 지원, 제작 지원을 위한 검증체계 구축 및 설계 검증장비 활용 지원 등 추진

▸ **('26년)** 시제품 및 양산품 제작 고도화(기능 등), 검증 핵심장비 구축 및 체계 고도화(종, 건 추가) 등

○ **[실증 · 고도화]** AI반도체 실증을 통한 레퍼런스 확보 지원

· **(수행)** 국산AI반도체 기반의 상용 데이터센터 등 인프라 구축·실증 및 다양한(의료·산업·에너지·도시) AI 응용서비스 기반 실증 지원 등 추진

▸ **('26년)** 실증 인프라 구축 고도화(PF 고도화, Farm 전환 추진 등), AX 실증지원 4개 분야 확대 등

○ **[생태계 조성]** AI반도체 全주기 분야의 제반(기술·인재·수요) 지원

· **(수행)** 설계 SW 공동활용 기술지원, AI반도체 우수 인재 발굴 및 신규채용, 분야별 신규 수요 발굴 및 협력 분과 운영 등 추진

▸ **('26년)** 클러스터(일몰)→설계SW(추진), 채용연계 상반기 조기 추진, K-NPU 얼라이언스 확대 개편(안) 마련 등

## □ [AI반도체전략팀] 사업별 세부내용

### ① AI반도체 Farm 구축 및 실증 실증·고도화 ['25년 일몰]

· **(개요)** 국산 AI반도체를 활용하여 **상용 데이터센터 구축** 및 **AI 응용서비스 실증** 기반의 국산 AI반도체의 **시장수요 조기창출** 및 **경쟁력 강화**

* 총 연산용량 약 20PF(peta-FLOPs), 8개 AI 응용서비스 실증

· **(수행)** '25년 AI 응용서비스 실증(4개) 추진 및 클라우드 플랫폼 고도화, AI반도체-AI모델 간 성능 최적화 등 추진

* ('23~24) 국산 **AI반도체 기반 컴퓨팅 인프라 구축** 및 **클라우드 플랫폼 구축·운영**, **AI 응용서비스 실증**(4개) 추진

| | |
|---|---|
| 쟁 점 사 항 ('25년) | ❶ **'25년 일몰'** 사업으로, **'AI컴퓨팅 실증인프라 고도화' 사업(추경)**으로 추진 |
| 고 려 사 항 ('26년) | ❶ 특이사항 없음 |

### ② AI컴퓨팅 실증인프라 고도화 실증·고도화 ['26년 사업비 : 16,000 백만원]

· **(개요)** LLM, 이기종 혼용서비스 등 **대규모 자원이 소요되는 AI서비스** 실증을 위해 **국산 NPU 기반의 인프라 구축** 및 실증 추진

* '27년까지 누적 155PF 규모로 구축 예정('25년 50PF, '26년 60PF, '27년 45PF)

· **(수행)** 25년 AI컴퓨팅 실증 인프라 50PF 구축 및 플랫폼 SW개발

* (26년) 독자 AI모델 오픈소스 공개시, 매칭된 기업의 모델 테스트 예정
(퓨리오사-엑사온(LG AI연구원), 리벨리온-에이닷엑스(SKT))

| | |
|---|---|
| 쟁 점 사 항 ('25년) | ❶ 차년도 예산 추가배정으로 인프라 확대를 위한 효율적 방안 검토<br>* 기존 구축사 구축 및 신규 구축사 구축 중 적합성에 대한 논의<br>** 신규 구축사 선정 절차에 대한 논의<br>→ 상기 논의를 통해 **하이퍼엑셀이 신규 구축사 후보기업**으로 예정 |
| 고 려 사 항 ('26년) | ❶ '26년 예산 추가 배정으로 **'27년까지 155PF 구축 예정**<br>* 기존 총 120PF ('25년 50PF, '26년 40PF, '27년 30PF) → 155PF ('25년 50PF, '26년 60PF, '27년 45PF)<br>** 신규 구축사 예정인 하이퍼엑셀의 경우, 인프라 구축을 위한 카드가 '26년 9월에 납품이 가능하여, 9월 이후 계약 및 사업 추진 가능 |

### ③ K-클라우드 얼라이언스 생태계 조성

· **(개요)** AI반도체분야 민-관, 수요-공급(AI반도체 팹리스, SW · HW, NPU社, AI모델·서비스기업 등) 간 **AI반도체 생태계 소통·협력 강화**

· **(수행)** '22년 발족이후, **정책공유, 산업계 애로사항 및 의견청취**를 위한 **전체회의**와 **분야별 신규 수요발굴**과 **협력**을 위한 분과운영

* 2025년 12월 기준 4회 전체회의 및 30회 분과회의를 진행, 153개사 산학연 참여

| | |
|---|---|
| 쟁점 사항 ('25년) | ❶ AI반도체 M.AX 얼라이언스, 피지컬AI 글로벌 얼라이언스 출범 등 민·관 협력 필요성이 대두되는 상황에서 **K-클라우드 얼라이언스의 전환점 필요**<br>❷ 「K-반도체 도약 전략 전문가 간담회」 후속조치 → **K-Perf 발족 및 성능 지표 발굴** |
| 고려 사항 ('26년) | ❶ 기존 K-클라우드 얼라이언스(22년~)를 **K-NPU 얼라이언스로 개편**하고 피지컬 AI, AX분야까지 포괄할 수 있도록 **확대 개편(안) 마련**<br>❷ K-NPU얼라이언스내 수요-공급기업, 공인시험인증기관(TTA) 등이 참여하는 'K-Perf 협의체' 구성·운영하여 **성능지표(K-Perf) 고도화·확산 도모** |

## □ [AI반도체확산팀] 사업별 세부내용

### ④ AI모델 맞춤형 설계지원 설계 ['25년 일몰]

· **(개요)** 국산 AI반도체와 국내·외 최신 AI모델의 최적화 및 기술호환성 확보 지원을 통해 AI반도체 시장 확대 및 경쟁력 기반 개선

· **(수행)** 최신 AI모델 등 다양한 SW와 국산 NPU간 기술호환성 확보를 위한 SW 라이선스 도입·연동 지원 및 맞춤형 설계 구조 구현 등 지원

**< (참고) AI모델 맞춤형 설계지원 (10개 개요) >**

| 구분 | 텔레칩스 | 보스반도체 | 하이퍼엑셀 | 넥스트칩 | 모빌린트 | 아이닉스 | 딥엑스 | 리벨리온 | 하이퍼엑셀 | 퓨리오사AI |
|---|---|---|---|---|---|---|---|---|---|---|
| 최적화 AI모델명 | YOLOv11n, PoseNet, AdaFace | Resnet50 Llama3 | GPT-OSS, Midm | YOLOv8, Deeplabv3 | Llama3, YOLOv12 | YOLO8m | CLIP, YOLOV11 | A.X-v4.2 | HyperCL OVAX, Solar-Pro2 | Exaone |
| 대상 AI반도체 | Dolphin 5 | Eagle-N | LPU(FPGA) | APACHE6 | ARIES | EN683 | DX-M1 DX-M2 | ATOM-MAX | LPU(FPGA) | RNGD |

| | |
|---|---|
| 쟁점 사항 ('25년) | ❶ 2차 추경 편성('25.7)에 따라 단년도 사업으로 추진 → **'25년도 일몰** |
| 고려 사항 ('26년) | ❶ '25년도 추경사업 일몰로, **'27년도 사업 신규 예산 반영 추진 中**<br>* '27년 중기예산(50억, 5개 과제) 반영 中, 2~3월 팹리스기업별 수요조사 진행<br>** '27년 **'AI모델 맞춤형 고도화 지원 및 설계IP활용지원' 신규 사업**으로 중기 신청 **(붙임1 참고)** |

## ⑤ AI반도체 설계 IP 활용지원 설계 ['25년 일몰]

· **(개요)** CPU(ARM, RISC-V)·인터페이스·메모리 컨트롤러 등 AI반도체 개발에 필수인 고비용 AI반도체 설계 IP 활용 지원

· **(수행)** 국내 팹리스사 10개 대상 NPU 수요 IP 31개 도입 지원 및 IP 연동구조 설계 · 성능검증 컨설팅 지원

* 수행기관 : 넥스트칩, 딥엑스, 모빌린트, 퍼앤퍼네트워크, 엣지에이아이, 하이퍼엑셀, 엑시나, 보스반도체, 디노티시아, 수퍼게이트

| | |
|---|---|
| 쟁점사항 ('25년) | ❶ 2차 추경 편성('25.7)에 따라 단년도 사업으로 추진 → **'25년도 일몰** |
| 고려사항 ('26년) | ❶ '25년도 추경사업 일몰로, **'27년도 사업 신규 예산 반영 추진 中**<br>* '27년 중기예산(200억, 10개 과제) 반영 中, 2~3월 팹리스기업별 수요조사 진행<br>** '27년 **'AI모델 맞춤형 고도화 지원 및 설계IP활용지원' 신규 사업**으로 중기 신청 **(붙임1 참고)** |

## ⑥ AI반도체 사업화 적시 지원 제작·검증 ['26년 사업비 : 30,000백만원]

· **(개요)** AI반도체 스타트업의 신속한 시장진출 지원을 위한 AI반도체 설계·제작·검증 등 사업화 단계별 지원체계 구축 지원

· **(수행)** '25년 설계SW 컨설팅 기술지원 17건, 양산급 3종 칩 고도화 및 시제품 10종의 국산 AI반도체 칩 제작 추진, 검증 체계 구축 및 활용 지원 등 추진

* (26년) 2~3월 기업별 수요조사 진행 예정

- **(❶설계SW)** 고비용 AI반도체 설계SW에 대한 기업수요 맞춤형 지원(바우처) 및 설계SW 전문 엔지니어의 수요기업 대상 컨설팅·기술 지원(총 17개社 지원, '26년 15개사 지원)
- **(❷제품제작)** 초기 설계검증 시제품 MPW 제작비용 지원(10개社) 및 양산품 수준 제품 구현 위한 SW 최적화, 칩보드 제작 등 기능고도화 지원(3개社)
  * ('26년) 시제품 제작지원 신규 10건, 양산급 기능고도화 지원 3건 예정
- **(❸검증체계)** 국산 AI반도체의 글로벌 상용화 기반 조성을 위한 검증체계 고도화로, 검증 핵심장비 구축(2종), 검증체계 고도화(1건), 검증(4건) 지원
  * ('26년) 검증 장비 구축(5종), 검증체계 고도화(1건), 검증지원(10건) 예정
- **(❹검증활용)** 설계 검증장비 활용을 통해 상용화에 필수적인 안정성·신뢰성 검증 지원(3개社, '26년 5개사 지원)
  * 케이던스社 팔라듐 Z1 장비 활용지원 통해 고성능 AI반도체 설계 디자인 성능검증 지원

| | |
|---|---|
| 쟁점사항 ('25년) | ❶ **(제품제작)** '30나노' 이상 선정대상 부재<br>❷ **(검증체계)** '26년 정책지정 예산 35억 증액 반영(총 예산 60억*)<br>* ('26) 기존 25억(민간위탁비 24억) ⇒ 60억(35억 증액, 민간위탁비 58억) |
| 고려사항 ('26년) | ❶ **(제품제작)** '26년 시제품 제작지원사업 **'지원분야' 조정 및 검토**<br>❷ **(검증체계)** '26년 예산 증액에 따라, 협약시 **'목표·내용' 재설정 및 검토** |

## ⑦ AI반도체 응용실증지원 실증·고도화 ['26년 사업비 : 4,685백만원]

· **(개요)** 국산 AI반도체(서버용·엣지용)에 **다양한 AI서비스를 적용**하여, 비공개 기능·성능 테스트 및 AI반도체 실증을 통한 **레퍼런스 확보 지원**

· **(수행)** '25년 AI응용서비스 수요 분야에 대한 실증 지원으로 **AI반도체 실증 레퍼런스 확보 계속·신규 10개 과제 레퍼런스 확보**

* (26년) 2~3월 기업별 수요조사 진행 예정

**< (참고) '25년 AI반도체 실증 지원과제 현황 >**

| 구분 | 지원 분야 | 수행기관 | 과제명 |
|---|---|---|---|
| 계속 과제 ('25년 일몰) | 지정 (드론) | (주관) 인투스카이<br>(참여) 세종대 산학협력단<br>(용역) 디퍼아이 | 국산 온디바이스 AI반도체 기반 장애물 회피 및 객체탐지용 AI 응용실증 |
| | 지정 (로봇) | (주관) 유원지리정보시스템<br>(참여) 케이알엠<br>(용역) 모빌린트 | 국산 엣지 AI반도체를 적용한 SLAM 기반 보안안전 및 정보수집용 4족보행로봇 개발 및 실증 |
| | 지정 (국방) | (주관) 엘아이지시스템<br>(참여) 솔빛시스템<br>(용역) 사피온코리아 | 엣지/서버용 AI반도체를 활용한 국방 감시정찰 드론체계 AI 응용실증 |
| | 자유 (차량) | (주관) 에스더블유엠<br>(참여) 한양대, 인하대산학협력단<br>(용역) 텔레칩스 | 국산 AI반도체 활용 전방 충돌 방지 시스템 응용실증 |
| | 자유 (워터마킹) | (주관) 마크애니<br>(참여) 서울대 산학협력단<br>(용역) 리벨리온 | 생성형AI 콘텐츠 진위 여부 판별을 위한 국산 NPU AI반도체 기반 고속 Invisible Watermarking 서비스 실증 |
| 신규 과제 ('26년 계속) | 지정 (안전·관제) | (주관) 코드비전<br>(용역) 퓨리오사에이아이 | 국산 AI반도체(NPU) 기반 제조 공정 AI 모니터링과 ML-Ops 운영 솔루션 국산화 및 실증 |
| | 지정 (보건·의료) | (주관) 딥노이드<br>(용역) 퓨리오사에이아이 | 국산 NPU를 활용한 초거대 언어 모델 기반 의료 영상 판독문 생성 AI 응용 서비스 실증 |
| | 지정 (지식서비스) | (주관) 워트인텔리전스<br>(용역) 리벨리온 | 특허기술문서 특화 분류요약 AI와 대화형 검색/번역 시스템의 국산 반도체 도입 실증 |
| | 지정 (국방) | (주관) 다온아이앤씨<br>(용역) 디퍼아이 | 국산 AI반도체를 적용한 실시간 멀티맵핑 및 직충돌 VTOL 드론 응용 실증 |
| | 지정 (교육) | (주관) 엘리스그룹<br>(용역) 리벨리온 | AI반도체 기반 교과서 정보 검증 및 교육용 질의응답 AI 에이전트 실증 |

**쟁점사항 ('25년)**

❶ 3자 검증 수행을 다수의 검증기관에서 수행함에 따라, **시험결과서에 사용된 용어 정의, 수행 방법 등이 상이**

❷ '25년 계속과제(5개) 일몰 사업

▼

**고려사항 ('26년)**

❶ 검증의 신뢰성과 비교 가능성을 제고하기 위해 **검증기관 통일 예정**

❷ AX 디바이스 과제의 내역으로(미니 트랙*), `26년 신규 예산(4,685백만원) 반영

* 국산 AI반도체 기반 AX 디바이스 개발·실증('26년 신규 사업 5건 공모 추진)

– 국산 AI반도체 응용실증 사례를 기반으로 상품화 수행을 위한 최적화 적용 및 공공조달 상품 등록(5건) 지원

## ⑧ AX 실증지원 실증·고도화 ['26년 사업비 : 16,000 백만원]

· **(개요)** 다양한 응용 AI서비스의 인프라를 **국산 NPU 기반으로 전환하고 실증을 수행함**으로써, 국산 AI반도체의 상용화 적용성과 확산 가능성 확보

· **(수행)** 4개 분야(의료, 산업, 에너지, 도시) 국산 NPU 기반 서비스 실증 추진

* (26년) 2~3월 기업별 수요조사 진행 예정

**< (참고) 서비스 실증 4개 분야 >**

| 구 분 | | 의료(치과교정) | 산업(양돈관리) | 에너지(원격검침) | 도시(도로관리) |
|---|---|---|---|---|---|
| '25년 | 목표 | 치과/병의원 5개소 | 돈축사 5개소 | 검침 현장 3개소 | 차량 시스템 10대 |
| | 성과 | 6개소 | 5개소 | 4개소 | 10대 |
| '26년 | 목표 | 15개소 | 30개소 | 10개소 | 40대 |

▸ **('25년 성과 실적)** 외산 GPU → 국산 NPU 기반 추론 인프라 전환,
서비스 실증 4건(기존 인프라 대비 성능 181% 달성, 비용 절감 37.5% 달성)

▸ **('26년 성과 계획)** 서비스 고도화, 실증 규모 확대(25년 대비 375% 이상),
서비스 출시 4건(기존 인프라 대비 성능 98%, 비용 절감 30% 이상 목표),
상용화 서비스 기준 시험검증 체계 마련 및 검증 수행(3자 검증)

▸ **('26년 추진 일정)** 서비스 및 인프라 고도화(~5월) → 3자 검증 및 현장 실증(~10월)
→ 서비스 출시(~12월)

**쟁점사항 ('25년)**

❶ NIPA **지역AX팀**에서 광주를 연고로 1차년도 AX실증지원 사업 수행
* AI반도체 사업 특성이 강하고, 산업분야별 시너지 확산 등의 쟁점으로 담당부서 이슈 발생

❷ 계속과제 예산이 실증확대 등의 이유로 국회 증액(80억→160억)

▼

**고려사항 ('26년)**

❶ '26년도부터 **AI반도체확산팀**으로 이관하여 추진

❷ 계속과제 4개 예산 20억 증액에 따라, **실증 구성 등의 사업범위 확대**

## ⑨ AI반도체 기술인재 공급 플랫폼 생태계 조성 ['26년 사업비 : 2,250백만원]

· **(개요)** 국내·외 AI반도체 인재 공급체계 구축으로 **수요기업이 즉시 활용할 수 있는 수준을 보유한 인력관리 및 채용연계 지원**

· **(수행)** AI Chip 캠프 등 운영, AI반도체 관련 교육·역량진단, 참가자 멘토링 등을 통해 **우수 인재 발굴(281명), 신규채용(61명) 연계**

* ('26년) 2~3월 기업별 수요 조사 진행 예정, 기업 인재 활용 지원(15개), 기업별 SW·HW 기술 인력 수요 정보 DB 구축 및 연간 상시 매칭

※ ('27년) 기업 인재 활용 지속 지원(5개) 후 일몰

| | |
|---|---|
| **쟁 점 사 항 ('25년)** | ❶ AI Chip 캠프 및 경연대회 위주 채용연계 추진 **(인재 풀 확보 방식 부족)**<br>❷ 이동엽 조사관 지적사항 : **채용연계 불균형(하반기 집중)**<br>※ '25년 하반기 인건비 집행 90% 이상 ⇨ 상반기 인건비 집행 저조 7% |

▼

| | |
|---|---|
| **고 려 사 항 ('26년)** | ❶ AI반도체 전문인력 **서치 펌**(헤드헌터社 및 채용솔루션社) **활용 채용연계 추진**<br>❷ **상반기 채용연계**(팹리스社↔기술인재) **조기 추진**으로 인건비 집행 예정 |

# 붙임1 AI모델 맞춤형 고도화 지원 및 설계IP활용지원 (27년 신규)

※ AI반도체 사업화 적시지원(내내역사업) 內 내내내역사업으로 추진

## □ 추진배경

○ **생성형 AI 및 도메인별 특화 AI 등 AI모델 종류가 급증**함에 따라, AI 반도체 상용화를 위해서는 **수요 분야별 다양한 AI모델을 지원**할 필요

- 특히, **도메인별 AI모델을 최적화하여 지원**하기 위해서는 **설계 단계**부터 **AI모델에 최적화된 구조 설계**가 요구

- 엔비디아는 **다양한 최신 AI모델**에 대한 **최적화 설계**를 바탕으로 **생성형AI, 자율주행차 등 유망 산업별 맞춤형 GPU 제공**

< AI모델별 특화 GPU 개발 사례 >

| 생성형 AI | | 자율주행차 | | 의료 AI | |
|---|---|---|---|---|---|
| 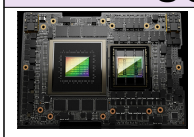 | | | 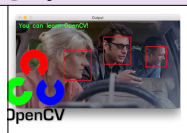 | | |
| GH200(Nvidia) | (美)HuggingFace | Drive Orin(Nvidia) | (美)OpenCV(OSS) | Clara AGX(Nvidia) | (美)MONAI(OSS) |

○ 국내 팹리스는 최근 **우수한 연산 성능을 지닌** NPU를 출시 중이나, **재정 여건 및 개발 환경 한계***로 YOLO 등 **대표적인 AI모델만을 지원**

* 2나노급 AI반도체 개발을 위해서는 고가 IP(디자인, SW) 활용, 설계 최적화 및 파운드리 비용 등 시제품 제작을 위해 8~900억원 소요

- 이에, 국산 NPU가 **범용성을 확보**할 수 있도록 설계 단계부터 **다양한 AI모델에 최적화된 설계를 지원**하여 **수요기업 확보 기반** 마련

## □ 사업내용

○ **(AI모델 맞춤형 고도화지원)** 최신 AI모델 등 **다양한 SW와 국산 NPU 간 기술호환성** 확보를 위한 **SW 라이선스 도입·연동 지원*** 및 **맞춤형 설계구조 구현** 등 지원(50억= 5개 x 5억)

* 국내 팹리스 기업이 다양한 AI모델을 지원하도록 설계구조를 보완하고, SDK, 미들웨어, 모듈화에 대한 지원 등 AI모델 연산 최적화 지원

- **(설계IP 활용지원)** CPU(ARM, RISC-V)·인터페이스·메모리 컨트롤러 등 AI반도체 개발에 필수인 고비용 **AI반도체 설계 IP 활용 지원***(200억 = 10개 x 20억)

* 고속 병렬연산, 데이터처리, 멀티채널 컨트롤 등 AI반도체 성능 구현 필수적인 디자인 IP에 대한 맞춤형 활용 및 기술컨설팅 등 지원

# 붙임2 K-AI반도체 풀스택 실증플랫폼 (27년 신규)

※ AI반도체 실증지원(세부사업) 內 내역사업으로 추진

## □ 사업개요

o **(목적)** 특화 AI워크로드별 **국산 AI반도체**에 대한 사전 성능검증 및 최적화를 **통해**, 국내 AI서비스 기업의 **국산 반도체 도입 확대**

- 국산 NPU 연산성능, 소비전력, AI워크로드 지원성능 등 실제 AI 서비스 제공 위해 AI반도체 도입 타당성에 대한 분야별 실증 지원

**<K-AI반도체 풀스택 실증플랫폼 >**

o **(지원내용)** 'AI반도체(HW)+ AI서비스(SW)'에 대한 Full-Stack 기술·장비 실증 지원, 국산 AI반도체의 유망분야 확산 캐즘*(Chasm) 극복

* 현재 퓨리오사AI, 리벨리온, 딥엑스 등 기업은 AI반도체 제품 출시 후, CUDA 중심 SW생태계, 핵심 부문 레퍼런스 부족 및 HW/SW 풀스택 생태계 미흡 등으로 캐즘(정체기)에 머물고 있음

① 실증수요 AI워크로드별 AI반도체 최적화 지원(100억)

- LLM, AI 비전 등 AI 서빙(Serving) 위한 커스텀 커널 개발, 양자화(경량화) 기술적용 및 프레임워크 호환성 검증 등 NPU 최적화 지원

* 제조, 로봇, 국방 등 국내 AI서비스 기업별 AI모델 및 국산 AI반도체 간 운영 최적화
* 10개 과제 × 10억원(최적화 지원) = 100억원

② AI반도체 최종제품(H/W) 제작 지원 및 실증(100억)

- 국산 AI서버, 보드 등 HW 및 AI반도체간 상호호환성 검증 후 최종 제품화 지원, 수요기업은 완제품 형태의 AI반도체 제품 활용

* NPU 서버, AI BOX(온디바이스) 등 최종 제품화 규격 검증, 기술인증 및 제작 등 통합 지원
* 10개 제품 × 10억원 = 100억원

# 붙임3 AI반도체 국내 · 외 시장 동향

## □ AI반도체 국내 · 외 동향

○ 빅테크·스타트업이 경쟁하며 앞다퉈 脫 엔비디아 시도

- (빅테크) 구글 등 **빅테크는** 자사(클라우드·기기·서비스)에 특화된 **맞춤형** AI칩을 **독자 개발**하며 脫 **엔비디아 움직임을 가속화**

< (참고) 구글의 풀스택(SW+HW) 전략 >

| | AI 반도체 | 클라우드 | AI 모델 | AI 서비스 |
|---|---|---|---|---|
| Google | TPU | GCP | 제미나이 | 제미나이·AI오버뷰 |

- (스타트업) **그록·삼바노바**(美), **텐스토렌트**(加), **캠브리콘**(中) 등은 NPU와 같이 특정 AI연산 효율을 극대화하는 **혁신적 아이디어**를 무기로 **기회 포착 노력**

* **(국외)** SambaNova: GPT-4의 3배에 달하는 매개변수를 가진 모델을 뒷받침하는 'SN40L' 출시('23.9)
Cerebras: 2022년 매출 발생(웨이퍼 스케일 칩 시스템 등 판매), 2024년 1.36억 달러 수준으로 성장

* **(국내)** 리벨리온, 딥엑스 등의 국내 기업은 1천만 달러 미만으로 파악되나, R&D 투자액은 지속적인 증가 추세

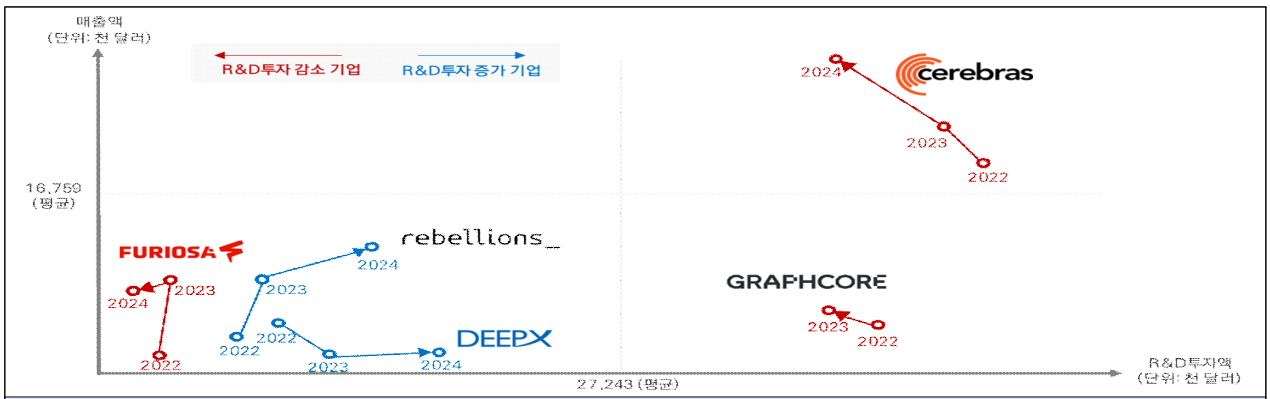


**국내.외 주요 NPU 기업의 매출액-R&D 투자액 현황** (출처: 현대경제연구원)

▸ **세계적으로 NPU를 설계하고 제공하는 스타트업**은 북미 26개, 아시아 9개, 유럽 5개, 중동 3개, 오세아니아 2개 등 **약 45개 내외**로 파악

* **(인수합병-完)** Graphcore(Softbank '24년 합병), Kinara(NXP '19년 합병), Habana(Intel '19년 합병), UNTETHER AI(AMD '25년 합병) 4개 기업

* **(인수합병-中)** SambaNova Systems(Intel은 약 16억 달러(약 2조 원)에 인수하기 위한 협상 진행 중

**글로벌 NPU 주요 스타트업 제품 현황**

- (국외) Groq, Hailo, Cerebras Systems, SiMa.ai, SambaNova Systems 등 주요 국외 AI 반도체 스타트업들은 **엔비디아 중심의 거대 시장에 도전**하며 저마다의 **독창적인 기술과 전략으로 AI 반도체 생태계를 확장** 中

**< 국외 주요 NPU 기업 현황 >**

| 구분 | 기업명(국가, 개업) | 사업 추진 방향 | 주요 공급 |
|---|---|---|---|
| 서버向 | Cerebras Systems (미국, 2015) | ▸ 초대규모 AI 모델 학습 및 추론을 위한 웨이퍼 스케일 엔진(WSE) 기반 시스템 개발 | ▸ CS-3 시스템: WSE-3 칩 기반 딥러닝 시스템 (2024년 출시) |
| | Groq (미국, 2016) | ▸ GroqCard, LLM 추론 전용 LPU(Language Processing Unit) 기반 클라우드 서비스 제공 | ▸ LPU™ Inference Engine: 데이터 센터에 구축된 추론 전용 프로세서로 서비스 제공 중 |
| | Biren Technology (중국, 2019) | ▸ 중국 내수 시장을 위한 고성능 AI 및 HPC GPU 개발 | ▸ BR100: 고성능 AI/HPC GPU (2022년 출시). Bili 시리즈: 현재 주력 생산 제품군 |
| | SambaNova Systems (미국, 2017) | ▸ 하드웨어 및 소프트웨어가 통합된 엔터프라이즈 AI 컴퓨팅 시스템 구축 | ▸ DataScale® / SambaStack™: RDU 기반의 랙 규모 솔루션 |
| | Cambricon (중국, 2016) | ▸ 중국 정부 지원 기반의 AI 칩 설계 및 제조 | ▸ Siyuan 590/690 (MLU590/690): 고성능 AI 가속기 칩(2023년 출시) |
| 엣지向 | Tenstorrent (캐나다, 2016) | ▸ AI 하드웨어 및 오픈소스 RISC-V 기반 칩렛 솔루션 개발 | ▸ BlackHole: 2세대 AI 프로세서 (2025년 출시) |
| | Hailo (이스라엘, 2017) | ▸ 엣지 디바이스(자율주행, 로봇, 스마트 시티 등)를 위한 고효율, 저전력 AI 프로세서 개발 | ▸ Hailo-8: 엣지 AI 프로세서 (2020년 이전). Hailo-10H: 2세대 엣지 AI 가속기 (2024년 공개) |
| | SiMa.ai (미국, 2018) | ▸ 엣지 디바이스에서 고성능 AI 구현, 저전력, 고효율의 SoC와 통합 소프트웨어 플랫폼 제공 | ▸ MLSoC Modalix (2세대): 멀티모달 AI (이미지, 비디오, 텍스트 처리), GenAI, LLM 지원 (2025년 출시) |

- (국내) 국내 10여개의 팹리스 AI반도체 기업들이 존재하며, **현재 제품개발 및 양산 작업에 매진**, **점진적 성장세**를 이어가고 있음

**< 국내 주요 NPU 기업 현황 >**

| 구분 | 기업명(개업) | 사업 추진 방향 | 주요 공급 |
|---|---|---|---|
| 서버向 | 리벨리온 (2020) | ▸ 엣지 및 데이터센터 특화 NPU 개발에 대한 1,650억원의 투자유치('24.1), 사피온과 합병 | ▸ ATOM-MAX: '25년 7월부터 총 5,400장(카드기준) 양산 |
| | 퓨리오사AI (2017) | ▸ WARBOY(1세대)를 출시하여 약 800억원의 투자유치('24.5) 및 레이게이드(2세대) NPU를 통한 수익 창출 기대 | ▸ 레니게이드: '25년 11월부터 총 1,200장(카드기준) 양산 |
| 엣지向 | 딥엑스 (2018) | ▸ 2024년 1월 DX-M1 엣지 특화 NPU 양산 시작 계획 발표, 저전력 온디바이스 AI 처리에 주력 | ▸ DX-M1: '25년 3~4분기 35,500장(카드기준) 양산 |
| | 모빌린트 (2021) | ▸ AI 및 메모리 반도체 기술 개발 기업, 2024년 4월 REGULUS를 출시, AI 칩 및 엣지 컴퓨팅용 고성능 반도체 솔루션 개발 중 | ▸ MLA100: '25년 7월부터 총 5,300장(카드기준) 양산 |